CORPORACIÓN UNIFICADA NACIONAL DE EDUCACIÓN SUPERIOR (CUN) · ESCUELA DE INGENIERÍA · ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL

CardioGuía RAG: guías clínicas cardiovasculares en una base vectorial en la nube

ACA 1 · Computación en la Nube para Sistemas Inteligentes · Docente: Hamilton Rivera Flor · Pilar: Salud

- Daimer Cardona Rojas
- Cristhian Eduardo Cortes Martha
- Juan Manuel Guerrero Tupaz
- Luis Alberto Ospina Delgado
- Jhonny Mauricio Rosero Carpio

Grupo 13
Noviembre de 2026

131
fragmentos de 3 guías del MinSalud (7.168 palabras) indexados en Qdrant Cloud

15 de 15
preguntas con la respuesta correcta entre los 3 primeros resultados (MRR 0,96)

78 ms
mediana de cada búsqueda en el clúster en la nube (p95: 88 ms)

US$0
costo de la canalización: usa el 0,074 % de la RAM gratuita de Qdrant

1 Situación problema

Las enfermedades isquémicas del corazón son la primera causa de muerte en Colombia: 92,7 defunciones por cada 100.000 habitantes en 2025 (Departamento Administrativo Nacional de Estadística [DANE], 2026).

Las recomendaciones para prevenirlas están en guías del Ministerio de Salud, en PDF de decenas de páginas. Buscar palabra por palabra falla con los sinónimos: quien escribe “tensión alta” no encuentra “hipertensión arterial”.

PREGUNTA ORIENTADORA

¿Cómo implementar en la nube una canalización de documentos, con una base vectorial serverless y un modelo de embeddings abierto, que recupere por significado información cardiovascular con alta precisión, costo cero y baja latencia?

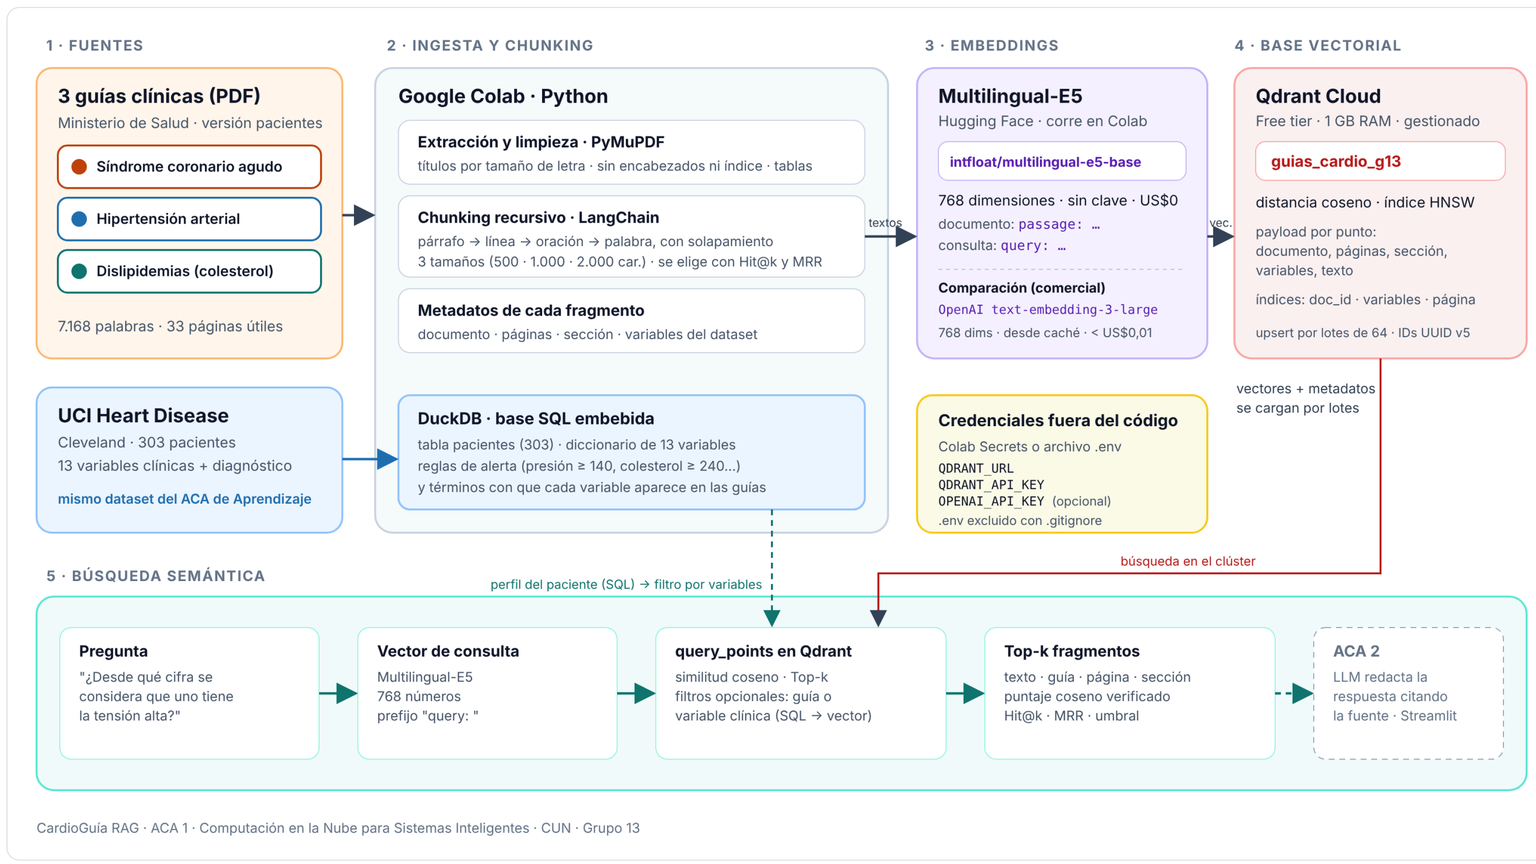
2 Objetivo general

Diseñar e implementar la ingesta, fragmentación, vectorización y almacenamiento semántico de tres guías clínicas en **Qdrant Cloud**, integradas con los metadatos del dataset UCI Heart Disease, y validar la búsqueda con métricas cuantitativas.

Complementa a CardioRiesgo (ACA de Aprendizaje Automático): el modelo dice qué tan alto es el riesgo; las guías, qué hacer con él.

3 Arquitectura cloud de datos

Figura 1
Canalización de ingesta, vectorización y búsqueda semántica de CardioGuía RAG



Nota. Elaboración propia. Las credenciales se leen de Colab Secrets o de un archivo `.env` excluido del repositorio.

4 Corpus y dataset

Tabla 1
Guías de práctica clínica del MinSalud (versión para pacientes)

Guía	Año	Páginas	Palabras
Síndrome coronario agudo	2013	8-26	3.982
Hipertensión arterial	2013	11-15	1.206
Dislipidemias (colesterol)	2014	9-17	1.980

Nota. Ministerio de Salud y Protección Social y Colciencias (2013a, 2013b, 2014). Se indexan solo las páginas de contenido.

Dataset base: UCI Heart Disease, Cleveland (Janosi et al., 1988): 303 pacientes y 13 variables clínicas, cargados en **DuckDB** con un diccionario de variables.

trestbps presión · **chol** colesterol · **fbs** glucemia · **cp** dolor torácico · **exang** angina · **restecg** ECG

Cada fragmento lleva en su payload las variables del dataset que menciona: así se cruza un paciente en SQL con las guías.

5 Ingesta y limpieza

- **PyMuPDF** lee bloques y tamaños de letra: detecta títulos y quita encabezados, pies, índices y recuadros repetidos.
- Las **tablas** se convierten en oraciones para que conserven su sentido al vectorizarlas.
- Cada fragmento guarda **guía, páginas, sección y variables** como metadatos.

6 Chunking justificado

Probamos tres tamaños con **LangChain RecursiveCharacterTextSplitter** (párrafo → oración → palabra) y 15 preguntas etiquetadas.

Tabla 2
Recuperación según el tamaño del fragmento (caracteres / solape)

Config.	Tamaño	Frag.	Hit@1	MRR	Separación
Pequeño	**500 / 75**	**131**	**0,93**	**0,96**	**0,13**
Mediano	1.000 / 150	62	0,80	0,89	0,12
Grande	2.000 / 200	28	0,87	0,93	0,12

Nota. Separación = coseno medio del primer resultado en preguntas del dominio menos el de 6 preguntas fuera del dominio.

Elegimos **pequeño** (500 caracteres, solape 75): mejor MRR, fragmentos de unos 90 tokens, una idea por fragmento, y el 95 % termina en una oración completa.

7 Stack tecnológico

ENTORNO	**Google Colab** · Python, CPU gratuita
SQL	**DuckDB** · pacientes y diccionario de variables
INGESTA	**PyMuPDF** · texto, títulos y tablas
CHUNKING	**LangChain Text Splitters** · recursivo con solape
EMBEDDINGS	**Multilingual-E5 base** · Hugging Face, 768 dims
BASE VECTORIAL	**Qdrant Cloud** · Free tier 1 GB, coseno, HNSW
SEGURIDAD	**Colab Secrets / .env** · sin claves en el código

8 Embeddings e indexación

intfloat/multilingual-e5-base (Wang et al., 2024): abierto, multilingüe y sin cuota. Usa los prefijos `query:` y `passage:`, el equivalente de `RETRIEVAL_QUERY`.

- **Batch upsert** en lotes de 64 con IDs UUID v5: recargar actualiza, no duplica.
- Distancia **coseno**, payload en disco e índices por guía, variable y página.
- 131 puntos = 0,40 MB de vectores: el 0,074 % de la capa gratuita.

Tabla 3
Modelo abierto frente a un modelo comercial (mismos 131 fragmentos y 15 preguntas)

Modelo	Hit@1	Hit@3	MRR	Separ.	Costo
Multilingual-E5 base Hugging Face · Colab	**0,93**	**1,00**	**0,96**	**0,13**	**US$0**
OpenAI text-embedding-3-large API de pago · desde caché	0,93	1,00	0,97	0,44	US$0,0016

Nota. Ambos con 768 dimensiones; OpenAI recortado con Matryoshka (Kusupati et al., 2022; OpenAI, 2024). Coinciden en el fragmento top-1 en 12 de 15 preguntas. E5 concentra sus cosenos en una franja estrecha: acierta casi igual, pero separa menos.

9 Consulta híbrida SQL + vector

DuckDB encuentra al paciente 127 (56 años, presión 200 mm Hg, colesterol 288 mg/dl). Sus alertas se vuelven un **filtro por variables** en Qdrant:

Tabla 4
Top-3 de la consulta híbrida SQL → vector

Guía	Sección del fragmento	Coseno
SCA · p. 21	¿Cómo interpreto la etiqueta de datos…	0,878
HTA · p. 14	¿Cómo estoy seguro que el tratamiento que…	0,861
HTA · p. 12	¿Quiénes están en mayor riesgo de tener…	0,859

10 Consultas semánticas

“Siento un dolor fuerte en el pecho que no se me quita, ¿qué debo hacer?”
SCA Síndrome coronario agudo · p. 26 · **coseno 0,883**
> Si nuevamente presenta dolor fuerte que oprime el pecho, que no mejora con el reposo y dura más de 30 minutos, debe…

Top-2 y 3: SCA 0,868 · SCA 0,862

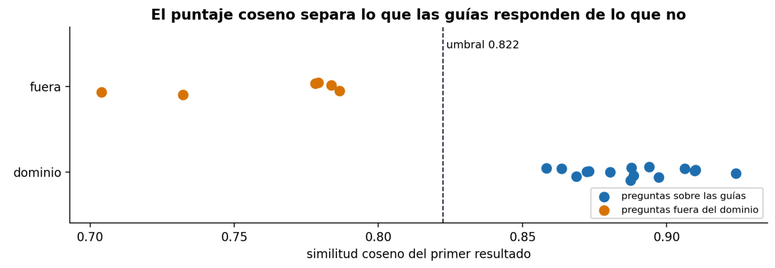
“¿Desde qué cifra se considera que uno tiene la tensión alta?”
HTA Hipertensión arterial · p. 12 · **coseno 0,835**
> Un profesional de la salud le hará esta medición apropiadamente. Si ésta se encuentra entre 140 y 160 (la primera cifra o…

Top-2 y 3: HTA 0,827 · HTA 0,815

“¿Qué alimentos debo evitar si tengo el colesterol alto?”
SCA Síndrome coronario agudo · p. 20 · **coseno 0,888**
> Los mariscos contienen poca grasa y son de buena calidad pero algunos, como los calamares, camarones, langostinos y la…

Top-2 y 3: SCA 0,884 · SCA 0,878

Figura 2
Coseno del primer resultado: preguntas del dominio frente a preguntas ajenas



Nota. Umbral: coseno ≥ 0,822, la mitad del hueco entre la pregunta ajena más alta (0,786) y la del dominio más baja (0,858). En el ACA 2 servirá para responder “no tengo información suficiente”.

11 Conclusiones

- La canalización corre en la nube a **costo cero**: 131 vectores ocupan el 0,07 % del clúster gratuito.
- El tamaño se eligió con datos: el fragmento **pequeño** logró el mejor MRR (0,956).
- El prefijo `query:` importa: sin él, Hit@1 baja de 0,93 a 0,80.
- E5, abierto y gratuito, rinde casi igual que OpenAI (MRR 0,956 frente a 0,967), y el umbral separa el 100 % de las preguntas.

REPOSITORIO (CÓDIGO Y DATOS)
github.com/lospinadel/RAG_Cardio
VIDEO DE SUSTENTACIÓN
youtu.be/4NfcRmYT4nE

Referencias

Chase, H. (2022). *LangChain* [Software]. GitHub. https://github.com/langchain-ai/langchain

Departamento Administrativo Nacional de Estadística. (2026, 20 de marzo). *En 2025pr disminuyen los nacimientos en Colombia en 4,5 % y aumentan las defunciones en 2,8 %* [Comunicado de prensa]. https://www.dane.gov.co/files/operaciones/EEVV/2026/20-mar-2026/cp-EEVV-Defunciones-IIsem2025pr.pdf

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart disease* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

Kusupati, A., Bhatt, G., Rege, A., Wallingford, M., Sinha, A., Ramanujan, V., Howard-Snyder, W., Chen, K., Kakade, S., Jain, P., & Farhadi, A. (2022). Matryoshka representation learning. *Advances in Neural Information Processing Systems, 35*, 30233–30249. https://arxiv.org/abs/2205.13147

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474. https://arxiv.org/abs/2005.11401

Ministerio de Salud y Protección Social & Colciencias. (2013a). *Guía de práctica clínica hipertensión arterial primaria (HTA): para pacientes y familiares* (Guía No. 18). https://www.minsalud.gov.co/sites/rid/Lists/BibliotecaDigital/RIDE/INEC/IETS/GPC_Ptes_HTA.pdf

Ministerio de Salud y Protección Social & Colciencias. (2013b). *Guía de síndrome coronario agudo para pacientes y cuidadores* (Guía No. GPC-2013-17). https://www.quindio.gov.co/home/docs/items/item_196/GPC_Ptes_SCA.pdf

Ministerio de Salud y Protección Social & Colciencias. (2014). *Guía de práctica clínica para la prevención, detección temprana, diagnóstico, tratamiento y seguimiento de las dislipidemias en la población mayor de 18 años: para pacientes y familiares* (Guía No. 27). https://www.minsalud.gov.co/sites/rid/Lists/BibliotecaDigital/RIDE/INEC/IETS/GPC-Dislipidemia-pacientes.pdf

OpenAI. (2024, 25 de enero). *New embedding models and API updates*. https://openai.com/index/new-embedding-models-and-api-updates/

Qdrant Solutions GmbH. (2024). *Qdrant documentation: Vector search engine & cloud database*. https://qdrant.tech/documentation/

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982–3992. https://arxiv.org/abs/1908.10084

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 text embeddings: A technical report* (arXiv:2402.05672). arXiv. https://arxiv.org/abs/2402.05672